

**UNIVERSIDAD NACIONAL DE INGENIERÍA
UNIDAD DE POSTGRADO FACULTAD DE INGENIERIA INDUSTRIAL Y DE
SISTEMAS**



PLAN DE TESIS

“TITULO”

**PARA OBTENER EL GRADO ACADEMICO DE MAESTRO EN CIENCIAS CON
MENCIÓN EN INTELIGENCIA ARTIFICIAL**

ELABORADA POR:

GABRIELA GRACIELA VILLEGAS VASQUEZ

LIMA, PERU

2025

DATOS GENERALES

1) TITULO DEL PLAN DE TESIS

“DISEÑO DE UN SISTEMA DE VISIÓN ARTIFICIAL BASADO EN REDES NEURONALES CONVOLUCIONALES (CNN) PARA LA DETECCIÓN TEMPRANA DE LA MOSCA BLANCA (ALEUROTHRIXUS FLOCCOSUS) EN OLIVOS (OLEA EUROPAEA) DEL BOSQUE EL OLIVAR, LIMA – PERÚ.”

2) NOMBRE DEL AUTOR

GABRIELA GRACIELA VILLEGAS VASQUEZ

3) NOMBRE DEL ASESOR O ASESORES

4) AREA INVOLUCRADA:

UNIDAD DE POSGRADO FIIS

5) LUGAR O INSTITUCION DONDE SE DESARROLLA EL PROYECTO

BOSQUE EL OLIVAR

DISTRITO DE SAN ISIDRO

MUNICIPALIDAD DE SAN ISIDRO

6) DURACION ESTIMADA DEL PROYECTO EN MESES

10 meses

fecha de inicio: octubre 2026

fecha de culminación: julio 2027

Capítulo 1:

Planteamiento del Problema

El Bosque El Olivar, ubicado en el distrito de San Isidro, Lima, constituye un ecosistema urbano patrimonial de alto valor histórico, cultural y ambiental, conformado mayoritariamente por individuos de olivo (*Olea europaea*).

Debido a su condición de área protegida, el manejo fitosanitario se encuentra sujeto a restricciones estrictas, particularmente en el uso de productos químicos de síntesis, con el objetivo de preservar el equilibrio ecológico y la biodiversidad asociada al bosque urbano.

En este contexto, la presencia recurrente de mosca blanca, especialmente especies del género *Aleurothrixus*, representa una problemática fitosanitaria constante, demasiado frecuente y agresiva no solo en el bosque, si no que ingresa a los jardines privados de los vecinos sanisidrinios.

Esta plaga afecta directamente la fisiología del olivo mediante la succión de savia, la producción de melaza y el desarrollo de fumagina, generando debilitamiento progresivo del follaje y disminución del vigor del árbol. La persistencia de estas infestaciones compromete la sanidad del arbolado urbano y dificulta la toma de decisiones oportunas en programas de manejo integrado de plagas.

Actualmente, la identificación de la mosca blanca en el Bosque El Olivar se basa principalmente en inspecciones visuales realizadas por personal técnico en campo. Este enfoque presenta limitaciones asociadas a la subjetividad del observador, la variabilidad en la experiencia del evaluador y la dificultad para detectar infestaciones en estadios tempranos, cuando los síntomas visibles aún no son evidentes. Estas condiciones evidencian la necesidad de incorporar herramientas tecnológicas que permitan mejorar la detección temprana, la objetividad del diagnóstico y la eficiencia del monitoreo fitosanitario.



Network: 25 jun 2025 1:22:34 p. m. GMT-05:00

Local: 25 jun 2025 1:22:33 p. m. GMT-05:00

12°6'5.62"S 77°2'1.6"W

150 Calle Machaypuito

Provincia de Lima

#ECOGREEN WORLD

Número de índice: 7700



Network: 10 jun 2025 8:49:04 a. m. GMT-05:00

Local: 10 jun 2025 8:49:04 a. m. GMT-05:00

12°5'59.432"S 77°2'5.953"W

264 Alameda Párroco Constancio Bollar

San Isidro

Provincia de Lima

#ECOGREEN WORLD

Número de índice: 7400



Network: 10 jun 2025 8:49:13 a. m. GMT-05:00

Local: 10 jun 2025 8:49:12 a. m. GMT-05:00

12°5'59.375"S 77°2'6.033"W

264 Alameda Párroco Constancio Bollar

San Isidro

Provincia de Lima

#ECOGREEN WORLD

Número de índice: 7401

1.1 Diagnóstico

El Bosque El Olivar presenta condiciones ambientales heterogéneas propias de un entorno urbano abierto, caracterizadas por variaciones de iluminación natural, presencia de sombras proyectadas por el follaje, fondos visuales complejos y alta interacción con actividades humanas. Estas características influyen directamente en la dinámica poblacional de plagas y en la efectividad de las labores de monitoreo fitosanitario.

Las evaluaciones actuales de mosca blanca se realizan mediante recorridos de campo y observación directa de hojas, ramas y brotes, enfocándose en la detección de síntomas visibles como melaza, fumagina y colonias de insectos. Si bien este método es funcional en infestaciones avanzadas, resulta poco eficiente para la identificación temprana de focos incipientes, especialmente en árboles de gran porte y copas densas, donde la visibilidad es limitada.

Asimismo, el proceso de diagnóstico depende en gran medida del tiempo disponible, la experiencia del personal técnico y las condiciones climáticas al momento de la inspección. Estas limitaciones reducen la capacidad de respuesta temprana frente a la plaga, lo que puede retrasar la aplicación de medidas de control biológico compatibles con el carácter patrimonial del bosque.

1.2 Identificación y Diagnóstico del Problema de Estudio

La gestión sanitaria del arbolado urbano en contextos patrimoniales demanda herramientas que permitan identificar tempranamente plagas sin recurrir a prácticas invasivas. En este escenario, la ausencia de sistemas automatizados de monitoreo limita la capacidad de respuesta técnica frente a la mosca blanca.

La detección tardía incrementa el riesgo de expansión poblacional de la plaga y retrasa la liberación oportuna de controladores biológicos, que constituye una de las principales estrategias permitidas dentro del Bosque El Olivar. Por tanto, existe una brecha tecnológica entre las necesidades reales del manejo fitosanitario urbano y las herramientas actualmente disponibles.

1.2.1 Antecedentes bibliográficos

Diversos estudios recientes han demostrado la viabilidad del uso de **visión por computador y aprendizaje profundo**, particularmente redes neuronales convolucionales (CNN), para la detección de plagas y enfermedades en cultivos agrícolas. Investigaciones aplicadas en cultivos como algodón, tomate, yuca y soya evidencian que los modelos basados en CNN permiten identificar patrones visuales asociados a infestaciones incluso en etapas tempranas.

No obstante, la mayoría de estos estudios se han desarrollado en **entornos agrícolas controlados o semi-controlados**, con escasa aplicación documentada en **bosques urbanos patrimoniales**, donde las condiciones ambientales, de iluminación y de manejo difieren significativamente. Asimismo, existe limitada literatura enfocada específicamente en la detección temprana de **mosca blanca en olivo urbano**, lo que refuerza la pertinencia del presente estudio.

Tusubira et al. (2020) desarrollaron un sistema de vigilancia de la mosca blanca en cultivos de yuca mediante dos enfoques: Haar Cascade y Faster R-CNN con ResNet-101. El estudio utilizó 7,500 imágenes de hojas infestadas, de las cuales 2,000 fueron anotadas manualmente, lo que implicó un alto costo de tiempo (aproximadamente 1,250 horas). Los resultados mostraron que el modelo Faster R-CNN alcanzó una precisión de 0.98 y un F1-score de 0.89, superando al Haar Cascade en desempeño. Sin embargo, el tiempo de inferencia fue relativamente alto (4.7 segundos por imagen) y la dependencia de infraestructura en la nube limitó su aplicabilidad en campo [Tusubira et al., 2020] .

1.2.2 Formulación del Problema

1.2.2.1 Formulación del Problema General

¿Cómo diseñar un sistema de visión artificial basado en redes neuronales convolucionales que permita la detección temprana de la mosca blanca (*Aleurothrixus floccosus*) en olivos del Bosque El Olivar, contribuyendo a una gestión fitosanitaria eficiente y compatible con las restricciones ambientales del entorno urbano patrimonial?

1.2.2.2 Formulación de los Problemas Específicos

¿Qué características visuales presentes en las hojas de olivo permiten identificar síntomas iniciales de infestación por mosca blanca mediante imágenes digitales?

¿Qué arquitectura de red neuronal convolucional resulta más adecuada para la detección temprana de mosca blanca en un entorno urbano con variabilidad lumínica?

¿Cuál es el nivel de precisión alcanzado por el modelo propuesto en comparación con la inspección visual tradicional?

¿Es viable implementar un sistema automatizado de detección que pueda ser replicable en otros espacios verdes urbanos?

1.2.3 Justificación y Alcances

1.2.3.1 Justificación

Desde el punto de vista técnico, esta investigación contribuye a la aplicación de técnicas de inteligencia artificial en el manejo fitosanitario del arbolado urbano, integrando conocimientos de agronomía, visión por computador y aprendizaje automático.

Desde el punto de vista ambiental, el desarrollo de un sistema de detección temprana permite optimizar el uso de control biológico, reduciendo la necesidad de intervenciones tardías y preservando el equilibrio ecológico del bosque.

Desde el punto de vista social e institucional, el proyecto aporta una herramienta objetiva y estandarizada para la toma de decisiones por parte de las entidades responsables de la gestión del Bosque El Olivar, fortaleciendo las prácticas de conservación del patrimonio verde urbano.

A diferencia de estudios como el de Tusubira et al. (2020), que se enfocaron en cultivos de yuca en Uganda, no existen investigaciones aplicadas a plagas urbanas patrimoniales como la mosca blanca en olivos del Bosque El Olivar. Este vacío refuerza la necesidad de desarrollar un sistema adaptado al contexto local.”

- Taxonomía de métodos en IA aplicada.
- Revisión comparativa: fortalezas y debilidades

1.2.3.2 Alcances

El estudio se limita a la detección temprana de la mosca blanca en hojas de olivo, utilizando imágenes capturadas en el Bosque El Olivar. No se abordará el desarrollo de métodos de control directo ni la identificación de otras plagas o enfermedades. El sistema propuesto se orienta a la detección e identificación, mas no a la erradicación de la plaga.

1.3 Objetivo General

El presente trabajo de investigación tiene como objetivo el diseño de un sistema de visión artificial basado en redes neuronales convolucionales (CNN) para la detección temprana de la mosca blanca (*Aleurothrixus floccosus*) en olivos (*Olea europaea*) del Bosque El Olivar, Lima – Perú.

1.4 Objetivos Específicos

Construir un conjunto de datos de imágenes de hojas de olivo con y sin presencia de mosca blanca.

Identificar y analizar características visuales relevantes asociadas a infestaciones tempranas.

Entrenar y evaluar un modelo CNN para la detección temprana de mosca blanca.

Comparar el desempeño del sistema propuesto con el diagnóstico visual tradicional.

Evaluar la viabilidad de replicar el sistema en otros espacios verdes urbanos.

Capítulo 2:

Marco Teórico y Estado del Arte

2.1 Bases Teóricas

- Fundamentos de IA (relacionados con la tesis).

La inteligencia artificial (IA) ha emergido como una herramienta poderosa en el ámbito agronómico, permitiendo el desarrollo de sistemas capaces de identificar patrones complejos en imágenes, optimizar procesos de monitoreo y mejorar la toma de decisiones en el manejo fitosanitario. En particular, el aprendizaje profundo ha demostrado ser eficaz en la detección de plagas y enfermedades mediante el análisis automatizado de imágenes.

- Las CNN son arquitecturas de aprendizaje profundo diseñadas para el procesamiento de datos visuales. Su capacidad para extraer características espaciales jerárquicas las hace ideales para tareas de clasificación y detección de objetos en imágenes agrícolas. Sin embargo, su implementación puede requerir recursos computacionales significativos y ajustes finos para entornos con alta variabilidad visual, como los espacios verdes urbanos.

- Metodologías de investigación tecnológica:

Yolov8s (versión pequeña) se utilizará con transferencia de aprendizaje, con la finalidad de aprovechar sus fortalezas como son:

1. Detectar los objetos como la mosca blanca en tiempo real
2. Es un método sencillo de implementar que CNN por ejemplo, además es más robusto que otros métodos clásicos
3. Permite trabajar en hardware accesible (Raspberry Pi o Laptop con GPU)
4. Tiene soporte para optimización y despliegue confiable en campo

Como complemento se utilizará:

- SAHI (Slicing Aided Hyper Inference)

Es una técnica que mejora la detección de objetos pequeños (como la mosca blanca) en imágenes grandes.

En lugar de analizar toda la imagen completa, divide la imagen en “trozos” (slices) y analiza cada trozo por separado. Luego, combina los resultados.

Si quisiéramos tomar las fotos de ramas completas o árboles, la mosca blanca será muy pequeña en comparación con la imagen total.

SAHI evita que el modelo “pierda” esos detalles.

Pudiendo utilizarlo en casos de plagas en estado juvenil de infestación (pequeñas) obtenidas en imágenes grandes, lo cual se ha referenciado en el paper de la lectura nro 04 (“Mejora de la detección y conteo de mosca blanca del algodón (*Bemisia tabaci*) con un enfoque de aprendizaje profundo rentable en Raspberry Pi)

Fortaleza:

Más precisión en condiciones reales (luz variable, fondo complejo).

Detecta plagas pequeñas en imágenes grandes.

2.3 Estado del Arte

Chand, Dhiman y Singh (2022) propusieron un enfoque de detección de mosca blanca en cultivos de algodón mediante técnicas de mejora de imágenes (contraste y DWT) y modelos de aprendizaje automático y profundo, incluyendo Decision Tree (DT), CNN, ResNet y CNN con atención. El estudio utilizó un dataset de 18,000 imágenes RGB, alcanzando precisiones de 81% con DT, 96% con CNN, 97.5% con ResNet y 98% con CNN con atención. La principal fortaleza del trabajo fue la robustez frente a variaciones de iluminación y ruido, gracias al preprocesamiento avanzado. Sin embargo, se reportaron altos costos computacionales y dependencia de grandes volúmenes de datos etiquetados, además de una validación limitada a una región geográfica específica (Punjab, India).

.

Bellout et al. (2024) realizaron una comparación exhaustiva de cinco modelos avanzados de la familia YOLO (YOLOv5, YOLOX, YOLOv7, YOLOv8 y YOLO-NAS) para la detección en tiempo real de enfermedades en hojas de tomate. El estudio utilizó un dataset combinado de PlantVillage y PlantDoc, con 3,325 imágenes distribuidas en tres clases (hoja sana, tizón tardío y mancha septoria). Los resultados mostraron que YOLOv5 alcanzó la mayor precisión promedio ($mAP@0.5 = 93.1\%$), mientras que YOLOv8 y YOLO-NAS ofrecieron mejoras en velocidad y eficiencia para dispositivos móviles. Una

de las principales fortalezas del trabajo fue la optimización para aplicaciones en smartphones, lo que facilita la implementación en campo. Sin embargo, el dataset estuvo limitado a tres clases y condiciones controladas, lo que restringe la generalización a escenarios más complejos.

- Zhang et al. (2023) desarrollaron un sistema automático de identificación de plagas en invernaderos mediante un modelo YOLOv5 mejorado. El estudio alcanzó una precisión del 96% en seis tipos de plagas, demostrando la aplicabilidad del enfoque en cultivos de tomate y fresa. Sin embargo, se reportaron limitaciones en la velocidad de procesamiento y en la detección de plagas extremadamente pequeñas.”

Capítulo 3: Metodología de Investigación

Feng et al. (2024) desarrollaron un sistema de detección y conteo de mosca blanca en algodón utilizando un modelo YOLOv8s mejorado con la incorporación de un Swin-Transformer en el backbone y una estructura P2 en la cabeza, complementado con la técnica SAHI para mejorar la detección de objetos pequeños. El dataset incluyó 1,200 imágenes originales, aumentadas hasta ~16,000 mediante técnicas de rotación, mosaico y contraste. El modelo alcanzó una precisión de 0.87, un recall de 0.89, un mAP50 de 0.92 y un F1-score de 0.88, mostrando alta correlación con conteos manuales ($R^2 = 0.977$). Una de sus principales fortalezas fue la implementación en Raspberry Pi con interfaz gráfica amigable, lo que permitió monitoreo en tiempo real y bajo costo. Sin embargo, el estudio se limitó a una región y cultivo específico, con riesgo de sobreajuste y necesidad de validación en condiciones más diversas.

3.1 Enfoque Metodológico

La presente investigación se enmarca dentro del enfoque de investigación tecnológica aplicada, orientada al desarrollo de soluciones prácticas mediante el uso de inteligencia artificial en contextos agronómicos urbanos. Se empleará una metodología híbrida que combina principios de Agile+AI para la gestión iterativa del desarrollo, junto con prácticas de MLOps (Machine Learning Operations) que permiten integrar, validar y desplegar modelos de aprendizaje automático de manera eficiente y reproducible.

El ciclo de investigación se estructura en cuatro fases:

- **Diseño:** Definición del problema, objetivos, arquitectura del modelo y criterios de evaluación.
- **Implementación:** Desarrollo del sistema de visión artificial, configuración del entorno de entrenamiento y aplicación de técnicas de aumento de datos.
- **Validación:** Evaluación del desempeño del modelo mediante métricas cuantitativas y comparación con métodos tradicionales.
- **Comunicación:** Documentación de resultados, elaboración de informes técnicos y difusión del conocimiento generado.

-Investigación tecnológica aplicada con Agile+AI y MLOps.
-Ciclo de investigación: diseño, implementación, validación, comunicación.

3.2 Diseño Experimental

3.2.1 Pipeline de Datos

El diseño experimental se basa en un pipeline de procesamiento de datos, el cual asegura la correcta preparación de la información visual antes del entrenamiento del modelo de detección. Las etapas consideradas son las siguientes:

a) Fuente de datos

Las imágenes serán obtenidas directamente del Bosque El Olivar, capturando hojas y ramas de olivos en condiciones reales de campo, incluyendo variaciones de iluminación, sombra, fondo y orientación. Las imágenes corresponderán tanto a hojas infestadas con mosca blanca (*Aleurothrixus floccosus*) como a hojas sanas.

b) Ingesta de datos

Las imágenes capturadas serán almacenadas en un repositorio estructurado, organizadas por clases (presencia y ausencia de plaga) y preparadas para el proceso de anotación manual mediante cajas delimitadoras (bounding boxes).

c) Preprocesamiento

El preprocesamiento incluirá:

Redimensionamiento de imágenes al tamaño requerido por YOLOv8.

Normalización de valores de píxeles.

Revisión de calidad de imágenes (eliminación de imágenes borrosas o irrelevantes).

d) Feature Engineering

En el caso de redes neuronales convolucionales, la extracción de características es realizada automáticamente por la red. Por lo tanto, no se aplicará feature engineering manual, sino que se aprovechará la capacidad del modelo para aprender patrones visuales relevantes directamente a partir de los datos.

e) Entrenamiento del modelo

El entrenamiento se realizará utilizando YOLOv8s con transferencia de aprendizaje, partiendo de pesos preentrenados. Se incorporarán técnicas de:

Aumento de datos (rotación, brillo, contraste, mosaico).

SAHI para mejorar la detección de objetos pequeños.

El entrenamiento se llevará a cabo en un entorno computacional accesible (laptop con GPU o entorno similar).

3.2.2 Estrategias de Validación

Para evaluar el desempeño del sistema propuesto, se utilizarán métodos de validación acordes al tamaño del conjunto de datos y al objetivo del estudio.

a) Validación Hold-out

El conjunto de datos será dividido en tres subconjuntos:

Entrenamiento

Validación

Prueba

Esta estrategia permitirá evaluar el desempeño del modelo sobre imágenes no vistas durante el entrenamiento.

Capítulo 3.3: Métricas de evaluación

(Precision, Recall, mAP, F1)

Se tomarán como referencia estudios previos como el de Tusubira et al. (2020), donde se emplearon métricas de precisión, recall, F1-score y mAP para evaluar modelos de detección de plagas

- Métricas: Se utilizarán las siguientes:

- [mAP@0.5](#) y [mAP@0.5:0.95](#) con la finalidad de evaluar la precisión promedio en diferentes umbrales de IoU
- Precisión con la finalidad de evaluar que tan exactas son las detecciones
- Recall para saber que tanto detecta todas las plagas presentes
- F1-score, para realizar un balance entre precisión y recall
- Tiempo de inferencia (ms), con esta métrica evaluamos, si funciona en tiempo real en campo

3.3 Interacción con Stakeholders

Plan de consultas y retroalimentación.

Se hizo las consultas: ¿El data set es actual, real del Bosque El Olivar o simulado?

- Sí, son imágenes reales.
Se toman fotos de hojas de Olivo, en el bosque El Olivar, estas hojas deberán estar con mosca blanca (en el envés de la hoja) en diferentes condiciones.
- En caso existan problemas con la cantidad de datos, se aplicara aumento de datos y regularización de los mismos.
- La captura de imágenes se realizará en diferentes horas del día (turno mañana y turno tarde), se realizará las tomas fotográficas en diferentes posiciones de las hojas, las que se encuentren altas, medias y bajas

Capítulo 4: Administración del plan de tesis

4.1 Cronograma

Número	Etapas	Actividades principales	Periodo
1	Habilitación de equipo y herramientas	Se elaborará un listado de materiales, útiles y herramientas de trabajo	Octubre 2026
2	Diseño y planificación	Revisión bibliográfica, revisión de objetivos, diseño del pipeline de datos y arquitectura del modelo	Octubre - noviembre 2026
3	Colecta, selección y preparación de datos	Toma de imágenes en campo, etiquetado, preprocesamiento y aumento de datos	Diciembre 2026 - enero 2027
4	Implementación del modelo	Entrenamiento de YOLOv8s con SAHI, ajuste de	Febrero y marzo 2027

		hiperparametros, pruebas iniciales.	
5	Validación experimental	Evaluación con K-Fold, bootstrapping y comparación con inspección visual	Abril -mayo 2027
6	Análisis y documentación	Interpretación de resultados, redacción de los capítulos para cierre, elaboración de conclusiones	Jun-27
7	Presentación y sustentación	Revisión y preparación de informe final y revisión final del plan de tesis	Jul-27
8	Imprevistos	En relación a la preparación del informe final	Jul-27

Oct 2026	Nov 2026	Dic 2026	Ene 2027	Feb 2027	Mar 2027	Abr 2027	May 2027	Jun 2027	Jul 2027

El desarrollo del proyecto se organizará en fases secuenciales, considerando un periodo de 10 meses (octubre 2026 – julio 2027), de acuerdo con la duración establecida en el plan de tesis.

Para evaluar el desempeño del sistema propuesto se utilizarán las siguientes métricas:

- $mAP@0.5$ y $mAP@0.5:0.95$, con la finalidad de evaluar la precisión promedio del modelo bajo diferentes umbrales de intersección sobre unión (IoU).
- Precisión (Precisión), para medir la exactitud de las detecciones realizadas por el sistema.
- Recall, para evaluar la capacidad del modelo de detectar la totalidad de las plagas presentes en las imágenes.

- F1-score, como métrica balanceada entre precisión y recall.
- Tiempo de inferencia (ms), para evaluar la viabilidad del sistema en aplicaciones en tiempo real en condiciones de campo.

4.2 Presupuesto

Categoría	Detalle	Monto (\$/.)
Equipos y tecnología	Laptop con GPU o servidor	4500
Equipos y tecnología	Raspberry Pi	600
Equipos y tecnología	Cámara digital o smartphone	1200
Software y herramientas	Librerías de IA	0
Logística y movilidad	Transporte para toma de datos	800
Materiales operativos	Material de oficina, impresión, almacenamiento	400
Asesoría técnica	Consultoría especializada	1000
Contingencias	Fondos para imprevistos	500
Asesoría técnica	Soporte técnico especializado en sistemas de información	6000
	TOTAL	15000

4.3 Financiamiento del proyecto se plantea a partir de colaboración institucional, con el objetivo de cubrir los costos estimados en el presupuesto.

Apoyo institucional directo

La Municipalidad de San Isidro cubrirá los costos asociados al equipamiento tecnológico (cámara digital, Raspberry Pi, laptop con GPU), así como los gastos de movilidad y logística para la toma de datos en campo.

- **Infraestructura y soporte técnico**

Se aprovechará la infraestructura disponible de la municipalidad para la captura de imágenes y monitoreo del bosque, además de contar con el acompañamiento de personal técnico en las labores de inspección y validación.

- **Financiamiento de asesoría especializada**

La municipalidad asumirá los costos de consultoría técnica en inteligencia artificial aplicada a la agronomía urbana, garantizando la calidad científica del proyecto.

- **Compromiso con la conservación patrimonial**

Al financiar el proyecto, la Municipalidad de San Isidro refuerza su compromiso con la preservación del Bosque El Olivar, asegurando que las estrategias de control biológico se implementen de manera oportuna y sustentada en evidencia científica.

- **Uso de software libre y recursos académicos**

El proyecto aprovechará plataformas de código abierto (YOLOv8, SAHI, PyTorch, OpenCV) y bibliotecas gratuitas, lo que permite reducir los costos de licencias y destinar los recursos a equipamiento y validación experimental.

Referencias Bibliográficas

- Zhang, X., Bu, J., Zhou, X., & Wang, X. (2023). Automatic pest identification system in the greenhouse based on deep learning and machine vision. *Frontiers in Plant Science*, 14, 1255719. [Frontiers | Automatic pest identification system in the greenhouse based on deep learning and machine vision](#)
- Tusubira, J. F., Nsumba, S., Ninsiima, F., Akeru, B., Acellam, G., Nakatumba, J., Mwebaze, E., Quinn, J., & Oyana, T. (2020). Improving in-field cassava whitefly pest surveillance with machine learning. *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, 2020, 1–10 [BAMSPProd: Un paso hacia la generalización de los métodos de optimización adaptativa al modelo binario profundo | Publicación de la Conferencia IEEE | IEEE Xplore](#)
- Chand, L., Dhiman, A. S., & Singh, S. (2022). Detection of whitefly pests in crops employing image enhancement and machine learning. *International Journal of Advanced Technology and Engineering Exploration*, 10(102), 569–579 [ACCENTS Journals](#)

- Feng, Z., Wang, N., Jin, Y., Cao, H., Huang, X., Wen, S., & Ding, M. (2024). Enhancing cotton whitefly (*Bemisia tabaci*) detection and counting with a cost-effective deep learning approach on the Raspberry Pi. *Plant Methods*, 20(161). [Mejorar la detección y el conteo de la mosca blanca del algodón \(*Bemisia tabaci*\) con un enfoque de aprendizaje profundo rentable en la Raspberry Pi | Métodos de plantas](#)
- Bellout, A., Zarboubi, M., Dliou, A., Latif, R., & Saddik, A. (2024). Advanced YOLO models for real-time detection of tomato leaf diseases. *Mathematical Modeling and Computing*, 11(4), 1198–1210 [Modelos avanzados de YOLO para la detección en tiempo real de enfermedades de las hojas de tomate | Revistas académicas y congresos](#)
- Aguirre-Rodríguez, E. Y., Rodríguez Gamboa, A. A., Aguirre Rodríguez, E. C., Santos-Fernández, J. P., Nascimento, L. F. C., da Silva, A. F., & Marins, F. A. S. (2025). Rice leaf disease detection using the Stretched Neighborhood Effect Color to Grayscale method and Machine Learning. *Scientia Agropecuaria*, 16(1), 123–136 <https://revistas.unitru.edu.pe/index.php/scientiaagrop/article/view/6223>

Anexos

Adjunto

1. Tabla de síntesis comparativa
2. Matriz de consistencia